Especificação do Projeto com Cronograma - Classificação de Tecido Tumoral por RNA-seq - Processamento de Dados

Ramo Estudantil IEEE - UEM

1. Visão Geral

Título do Projeto: Esse tecido é tumoral ou não tumoral? Classificação de tecidos de câncer de mama a partir de dados de expressão gênica.

A diferenciação entre tecidos tumorais e não tumorais (saudáveis) é fundamental para o diagnóstico em oncologia. O método tradicional, a análise histopatológica com microscopia óptica, exige exame minucioso, é demorado e está sujeito a divergências de interpretação entre especialistas.

O sequenciamento e a quantificação de RNA (RNA-seq) permitem medir digitalmente a expressão de milhares de genes de uma amostra ao mesmo tempo. Como tumores alteram esse perfil de forma consistente, este projeto propõe automatizar a classificação tumoral/não tumoral diretamente a partir desses dados, com técnicas de reconhecimento de padrões vistas no ciclo 4.

Este documento atende à entrega "Especificação do projeto com cronograma" dos Projetos Integradores Finais e define o que o grupo vai construir, com quais dados, como e em que prazo.

Os beneficiários da solução são pesquisadores, biomédicos, profissionais de hospitais e estudantes.

2. Objetivos

O objetivo do MVP é construir, em um notebook reprodutível no Google Colab, um fluxo de aprendizado de máquina que processe uma matriz de expressão gênica, aplique redução de dimensionalidade (PCA) e treine classificadores supervisionados (k-NN e Regressão Logística) capazes de identificar se o tecido é tumoral (1) ou não tumoral (0) partir de dados de RNA-seq de tecido tumoral de câncer de mama.

- Aplicar PCA para reduzir os 17.814 genes a poucos componentes principais e visualizar a separação entre os tecidos.
- Treinar e comparar k-NN e Regressão Logística na tarefa binária tumoral/não tumoral.
- Avaliar os modelos com métricas adequadas a classes desbalanceadas.
- Identificar os genes de maior peso na separação entre as classes.
- Garantir que qualquer pessoa consiga reproduzir os resultados seguindo o README do repositório.

3. Escopo do Projeto

3.1. Fonte de Dados

Será utilizado o dataset público Gene Expression Profiles of Breast Cancer, subconjunto BC-TCGA, os dados vêm do The Cancer Genome Atlas (TCGA). Disponível no Kaggle:

Link:https://www.kaggle.com/datasets/saurabhshahane/gene-expression-profiles-of-breast-cancer?select=BC-TCGA

- 590 amostras de tecido de mama: 529 tumorais e 61 normais.
- 17.814 genes por amostra.
- Os dados brutos não serão versionados no GitHub; o README explicará como obtê-los.

Na semana 1, nós confirmaremos as contagens, a presença de valores ausentes e se os arquivos trazem o identificador do paciente de cada amostra.

3.2. Abordagem Técnica

- Carregamento e limpeza dos dados no Google Colab, com pandas e scikit-learn.
- Simplificação do problema para binário (0 = não tumoral, 1 = tumoral).
- Tratamento da matriz: verificação e preenchimento de nulos e padronização das expressões gênicas (StandardScaler).
- Aplicação de PCA e gráfico de dispersão dos tecidos nos dois primeiros componentes.
- train_test_split(..., stratify=target_bin), seguido do treino de KNeighborsClassifier e LogisticRegression sobre os componentes ou genes selecionados.
- Avaliação com classification_report e confusion_matrix, observando especialmente o recall da classe não tumoral, já que há cerca de 9 amostras tumorais para cada normal.

3.3. Fora do Escopo

- Não serão desenvolvidas telas nem softwares executáveis (protótipos); o entregável é o notebook no Google Colab.
- Uso clínico ou diagnóstico real: o resultado é um estudo.
- Processamento de dados brutos de sequenciamento; partimos da matriz já quantificada.
- Classificação de subtipos de câncer de mama ou de outros tipos de câncer.
- Redes neurais e modelos além de k-NN e Regressão Logística.

4. Cronograma

O projeto vai de 26/10 a 12/12, em sete semanas. Cada marco pode ser conferido no repositório do projeto. Cada entrega será publicada no repositório do projeto até as 23h59 da data indicada.

A apresentação presencial acontecerá na data definida pelo Ramo, entre 30/11 e 20/12.

Semana	Período	Atividades	Marco Verificável
1	26/10 - 01/11	Entrega desta especificação (26/10). Criação do repositório; download e conferência do BC-TCGA	Repositório público com README e instruções de download; contagens de amostras confirmadas
2	02/11 - 08/11	Limpeza, tratamento de nulos, rótulo binário e análise exploratória	Notebook com contagem por classe e distribuição das expressões
3	09/11 - 15/11	Padronização e PCA	Gráfico de dispersão dos tecidos no PCA e gráfico de variância explicada
4	16/11 - 22/11	Análise de Requisitos (19/11). Primeira versão de k-NN e Regressão Logística	Documento de requisitos publicado; primeiras métricas dos dois modelos
5	23/11 - 29/11	Checkpoint (23 a 27/11). Ajuste de hiperparâmetros e genes de maior peso	Tabela comparando os modelos; lista dos genes mais relevantes
6	30/11 - 06/12	Avaliação final, documentação técnica e slides da apresentação	Rascunho da documentação técnica com resultados; slides prontos
7	07/12 - 12/12	Documento de desenvolvimento futuro, teste de reprodutibilidade e entrega final (12/12)	Notebook roda do zero seguindo só o README; três documentos no repositório

5. Estrutura Operacional e Governança

5.1 Divisão de Responsabilidades

Todos os integrantes participam de todas as etapas e entregas. Cada frente tem um responsável principal, que acompanha o andamento e garante o marco da semana.

- **Dados** (download, limpeza e instruções de obtenção): Yasmin
- **Análise exploratória e PCA**: Artur
- **Modelos e avaliação** (k-NN, Regressão Logística e métricas): Vivian
- **Interpretação dos genes e documentação técnica**: Vivian, Isabella, Yasmin e Artur
- **Repositório, cronograma e documento de desenvolvimento futuro**: Isabella

5.2 Ferramentas de Apoio

- **GitHub:** repositório público com notebook, README e documentos de entrega.
- **Google Colab:** desenvolvimento e execução do notebook.
- **Google Drive:** materiais editáveis e referências, na pasta do projeto.
- **Grupo de mensagens:** comunicação do dia a dia (Whatsapp)
- **Reunião quinzenal curta:** conferência do marco dos últimos dias e divisão das tarefas seguintes.

Isabella Barela, Vivian Kaori, Yasmin e Artur

Maringá, 26 de outubro de 2026